

Guia de Alterações

BH News Chatbot

Este documento descreve as funcionalidades adicionadas recentemente ao projeto, ensina como usá-las e responde às dúvidas mais comuns.

Repositório: github.com/paraenseembh/opensource_bh

Branch: `claude/bh-news-chatbot-NWtrw`

Contents

1	O que foi adicionado	2
2	Script de verificação de APIs (<code>test_api.py</code>)	2
2.1	Para que serve	2
2.2	Como executar	2
2.3	Como interpretar a saída	2
2.4	O que cada teste verifica	3
3	Integração com Maritaca.ai (Sabiá)	3
3.1	O que é a Maritaca	3
3.2	Modelos disponíveis	4
3.3	Como obter a chave	4
3.4	Como configurar	4
3.5	Como usar no chatbot	4
3.6	Verificar se a chave está funcionando	4
4	Comparativo de provedores	5
5	Instalação após as alterações	5
6	Perguntas frequentes	5
6.1	Os testes de erros passam mesmo sem SDK instalada. Isso está certo? . . .	5
6.2	Por que os testes funcionais ficam como - (pulado)?	5
6.3	Posso usar mais de um provedor ao mesmo tempo?	5
6.4	Como saber qual provedor está sendo usado no chat?	5
6.5	O teste “modelo inexistente” fica como - mesmo com chave válida. Por quê? .	6
6.6	O que fazer se <code>complete()</code> falhar com erro de autenticação?	6
6.7	Como usar o modelo rápido para reduzir custos?	6
6.8	O token do GitHub é necessário para usar o chatbot?	6
7	Referência rápida de comandos	6

O que foi adicionado

Alteração	Descrição	Arquivo
Script de verificação	Testa conectividade, <code>complete()</code> , <code>stream()</code> e tratamento de erros de cada provedor	<code>test_api.py</code>
Testes de erros	Verifica que o sistema rejeita chaves inválidas, modelos inexistentes e provedores desconhecidos	<code>test_api.py</code>
Maritaca (Sabiá)	Terceiro provedor de LLM, focado em português brasileiro	<code>llm_provider.py</code>
Dependência <code>openai</code>	Necessária para comunicar com a API compatível da Maritaca	<code>requirements.txt</code>
Flag <code>--maritaca-key</code>	Permite passar a chave da Maritaca pela linha de comando	<code>main.py</code>

Script de verificação de APIs (`test_api.py`)

Para que serve

Antes de rodar o chatbot, use este script para confirmar que suas chaves de API estão corretas e que os provedores estão respondendo. Ele executa dois grupos de testes:

- **Testes funcionais:** chamam a API de verdade com uma mensagem simples. Precisam de chave válida.
- **Testes de erros esperados:** verificam que o sistema rejeita situações inválidas corretamente. **Não precisam de chave.**

Como executar

```
# Testa todos os provedores configurados
python bh_news_chatbot/test_api.py

# Testa apenas um provedor
python bh_news_chatbot/test_api.py --provider anthropic
python bh_news_chatbot/test_api.py --provider gemini
python bh_news_chatbot/test_api.py --provider marataca

# Roda apenas os testes de erros (nao precisa de nenhuma chave)
python bh_news_chatbot/test_api.py --only-errors
```

Como interpretar a saída

```
[check] verde    -- teste passou
[x]        vermelho -- teste falhou (veja o motivo na mesma linha)
[-]        amarelo -- teste pulado (motivo entre parenteses)
```

Exemplo de saída com chave configurada:

```

Maritaca
-----

testes funcionais
[ok] create_provider()   Maritaca (sabia-4)
[ok] complete()          1.3s  "OK"
[ok] stream()            1.1s  4 token(s)  "OK"

erros esperados
[ok] chave vazia -> ValueError
[ok] chave invalida -> complete() falha
[ok] chave invalida -> stream() falha
[ok] modelo inexistente -> complete() falha

```

Exemplo sem chave configurada:

```

Maritaca
-----

testes funcionais
[-] todos os testes funcionais (MARITACA_KEY nao configurada)

erros esperados
[ok] chave vazia -> ValueError
[ok] chave invalida -> complete() falha  (ModuleNotFoundError)
[ok] chave invalida -> stream() falha
[-] modelo inexistente -> complete() falha (requer chave valida)

```

Os testes funcionais ficam com -- se a chave não estiver configurada. Isso é normal — configure a chave e rode novamente.

O que cada teste verifica

Teste	O que valida
<code>create_provider()</code>	A fábrica cria o objeto do provedor sem erros
<code>complete()</code>	A API responde a uma mensagem simples
<code>stream()</code>	A API retorna tokens em streaming
chave vazia → <code>ValueError</code>	O sistema rejeita chave em branco antes de chamar a API
chave inválida → <code>complete()</code> falha	A API retorna erro de autenticação para chave falsa
chave inválida → <code>stream()</code> falha	Idem, no modo streaming
modelo inexistente → <code>complete()</code> falha	A API retorna erro para nome de modelo inválido

Integração com Maritaca.ai (Sabiá)

O que é a Maritaca

A [Maritaca AI](#) é uma empresa brasileira que desenvolve modelos de linguagem otimizados para o português. Os modelos da família **Sabiá** têm desempenho superior em textos em português em relação a modelos genéricos do mesmo tamanho.

Modelos disponíveis

Modelo	Custo	Uso recomendado
sabia-4	Mais alto	Chat principal, respostas de maior qualidade
sabiazinho-4	Mais baixo	Categorização, tarefas rápidas, menor latência

Como obter a chave

1. Acesse plataforma.maritaca.ai/chaves-de-api
2. Crie uma conta (novos usuários recebem R\$ 20 de crédito)
3. Gere uma nova chave de API

Como configurar

```
# Variavel de ambiente (recomendado)
export MARITACA_KEY=sua-chave-aqui

# Ou passe direto na linha de comando
python bh_news_chatbot/main.py --provider marataca --maritaca-key sua-chave-aqui
```

Como usar no chatbot

```
# Uso basico com Sabia-4
python bh_news_chatbot/main.py --provider marataca

# Com modelo rapido (menor custo)
python bh_news_chatbot/main.py --provider marataca --model sabiazinho-4

# Com categorizacao e 5 artigos por area
python bh_news_chatbot/main.py --provider marataca --max-per-area 5 --categorize

# Apenas categorizar sem abrir o chat
python bh_news_chatbot/main.py --provider marataca --only-categorize
```

Verificar se a chave está funcionando

```
export MARITACA_KEY=sua-chave-aqui
python bh_news_chatbot/test_api.py --provider marataca
```

Comparativo de provedores

Provedor	Env var	Modelo chat	Modelo rápido	Foco
Anthropic	ANTHROPIC_API_KEY	claude-sonnet-4-6	claude-haiku-4-5	Texto
Google Gemini	GEMINI_API_KEY	gemini-2.0-flash	gemini-2.0-flash	Flash multi-modal
Maritaca	MARITACA_KEY	sabia-4	sabiazinho-2	Português BR

Para projetos de legislação municipal em português como este, a Maritaca tende a produzir respostas mais naturais e precisas no idioma.

Instalação após as alterações

Se você já tinha o projeto instalado, atualize as dependências para incluir o SDK `openai` (necessário para a Maritaca):

```
pip install -r bh_news_chatbot/requirements.txt
```

Ou instale apenas o novo pacote:

```
pip install "openai>=1.0.0"
```

Perguntas frequentes

Os testes de erros passam mesmo sem SDK instalada. Isso está certo?

Sim. Testes como “chave inválida → `complete()` falha” verificam apenas que *alguma exceção é lançada*. Sem o SDK instalado, o Python lança `ModuleNotFoundError` antes mesmo de chamar a API — o teste ainda passa porque o comportamento esperado (falha) ocorreu. Com o SDK instalado e chave inválida, seria lançado um `AuthenticationError` da API.

Por que os testes funcionais ficam como - (pulado)?

Porque a chave de API não está configurada. Configure a variável de ambiente e rode novamente:

```
export ANTHROPIC_API_KEY=sk-ant-...
python bh_news_chatbot/test_api.py --provider anthropic
```

Posso usar mais de um provedor ao mesmo tempo?

Não simultaneamente — você escolhe um por execução com `--provider`. Mas pode ter as três chaves configuradas e alternar conforme precisar.

Como saber qual provedor está sendo usado no chat?

O banner inicial do chatbot exibe o nome do provedor ativo:

```
Decretos carregados (Maritaca (sabia-4)):  
  * Area X: 10 documento(s)  
  ...
```

O teste “modelo inexistente” fica como - mesmo com chave válida. Por quê? Verifique se a chave está configurada com `export` e não apenas como assignment simples:

```
export ANTHROPIC_API_KEY=sk-ant-...    # correto  
ANTHROPIC_API_KEY=sk-ant-...          # errado -- nao fica no ambiente do  
subprocesso
```

O que fazer se `complete()` falhar com erro de autenticação?

1. Verifique se a chave está correta e sem espaços extras
2. Verifique se a chave não expirou ou foi revogada
3. Para Anthropic: confirme créditos em console.anthropic.com
4. Para Maritaca: confirme o saldo em plataforma.maritaca.ai
5. Para Gemini: confirme que a API está habilitada no [Google AI Studio](https://aistudio.google.com)

Como usar o modelo rápido para reduzir custos?

O modelo rápido é usado automaticamente na categorização interna. Para o chat, passe `--model` explicitamente:

```
# Anthropic -- modelo barato  
python bh_news_chatbot/main.py --provider anthropic --model claude-haiku  
-4-5-20251001  
  
# Maritaca -- modelo barato  
python bh_news_chatbot/main.py --provider maratoca --model sabiazinho-4  
  
# Gemini -- flash ja e o padrao  
python bh_news_chatbot/main.py --provider gemini --model gemini-2.0-flash
```

O token do GitHub é necessário para usar o chatbot?

Não. O token do GitHub é usado apenas para operações no repositório (push, pull, consultas à API). O chatbot precisa apenas das chaves de LLM: `ANTHROPIC_API_KEY`, `GEMINI_API_KEY` ou `MARITACA_KEY`.

Importante: nunca compartilhe tokens ou chaves de API em conversas, issues ou commits. Se isso acontecer, revogue imediatamente o token no painel do serviço correspondente.

Referência rápida de comandos

```
# Verificar APIs antes de usar  
python bh_news_chatbot/test_api.py  
  
# Inspeccionar o cache de artigos
```

```
python bh_news_chatbot/debug.py

# Iniciar o chatbot (Anthropic)
python bh_news_chatbot/main.py

# Iniciar o chatbot (Gemini)
python bh_news_chatbot/main.py --provider gemini

# Iniciar o chatbot (Maritaca)
python bh_news_chatbot/main.py --provider maritaca

# Forçar re-download dos artigos
python bh_news_chatbot/main.py --refresh

# Categorizar artigos e ver relatorio
python bh_news_chatbot/main.py --only-categorize

# Limpar cache manualmente
rm bh_news_chatbot/cache/news_cache.json
rm bh_news_chatbot/cache/categories_cache.json
```